

Tema 4- Modelos de Razonamiento

Introducción

Razonar consiste en inferir conclusiones a partir de un conocimiento previo y de la evidencia observada en el entorno. Es importante no confundirlo con la "búsqueda" (que consiste en explorar estados) ni con el "aprendizaje" (que extrae conocimiento a partir de datos brutos).

Existen dos grandes enfoques o modelos de razonamiento:

- **Modelos Categóricos:** Operan en dominios marcadamente simbólicos donde las soluciones se pueden establecer con total y absoluta certeza.
- **Modelos Probabilísticos:** Operan en dominios estadísticos donde reina la incertidumbre y las soluciones no son unívocas.

Modelo categórico (Razonamiento exacto)

Este modelo establece relaciones causales estrictas entre las **Manifestaciones** (los síntomas o evidencias, variables **X**) y las **Interpretaciones** (las causas o diagnósticos, variables **Y**) mediante funciones lógicas.

$$X = \{\text{manifestaciones}\} = \{x_1, x_2, \dots, x_n\}$$

$$Y = \{\text{interpretaciones}\} = \{y_1, y_2, \dots, y_m\}$$

$$E = E(X, Y)$$

Conocimiento

El proceso deductivo (BLE vs BLR):

- El sistema parte de una **Base Lógica Expandida (BLE)**, que es la combinación de todas las manifestaciones posibles con todas las interpretaciones posibles. En esta base existen muchas combinaciones que son directamente absurdas.
- El conocimiento del experto actúa como un filtro lógico (reglas IF-THEN) que elimina esas combinaciones imposibles, reduciendo el problema a una **Base Lógica Reducida (BLR)**. La solución final a cualquier problema siempre se encontrará dentro de esta BLR.
- Analogía: Imagina que la BLE es un lienzo con todas las combinaciones imaginables de animales (ej. un perro con alas y escamas). El conocimiento experto (las reglas de la biología) actúa como un colador que elimina los animales imposibles, dejando en la BLR solo los animales que biológicamente pueden existir.

Ventajas: Es un sistema exacto, formalmente muy sólido y 100% explicable.

Limitaciones Críticas: No es capaz de manejar la incertidumbre, es muy frágil ante el "ruido" (un solo dato erróneo tumba la deducción) y requiere un conocimiento del dominio completamente exhaustivo para funcionar.

Procedimiento

1. Identificación de M
2. Identificación de I
3. Construcción de E
4. Construcción del conjunto completo de complejos de manifestaciones
5. Construcción del conjunto completo de complejos de interpretaciones
6. Construcción del conjunto completo de complejos manifestación-interpretación

Ejemplo

Sea un dominio D caracterizado por

- Manifestaciones $M = \{m(1), m(2)\}$
- Interpretaciones $I = \{i(1), i(2)\}$

En el que el conocimiento incluye las siguientes relaciones causales

- Para que $i(2)$ sea cierta, $m(1)$ debe estar presente $R_1: i(2) \rightarrow m(1)$
- Para que $i(1)$ sea cierta, e $i(2)$ sea falsa, $m(2)$ debe estar presente $R_2: i(1) \wedge \neg i(2) \rightarrow m(2)$
- Para que $i(2)$ sea cierta, e $i(1)$ sea falsa, $m(2)$ no debe estar presente $R_3: i(2) \wedge \neg i(1) \rightarrow \neg m(2)$
- Si alguna manifestación está presente es porque se puede establecer alguna interpretación $R_4: m(1) \vee m(2) \rightarrow i(1) \vee i(2)$

$$E = \{R_1, R_2, R_3, R_4\}$$

$$f[M(i), m(j)] = \neg m(i) \wedge m(j)$$

$E: \{g \rightarrow g\}$

$$R_1: i(2) \rightarrow m(1) \equiv \neg i(2) \vee m(1)$$

$$R_2: i(1) \wedge \neg i(2) \rightarrow m(2) \equiv \neg i(1) \vee i(2) \vee m(2)$$

$$R_3: i(2) \wedge \neg i(1) \rightarrow \neg m(2) \equiv \neg i(2) \vee i(1) \vee \neg m(2)$$

$$R_4: m(1) \vee m(2) \rightarrow i(1) \vee i(2) \equiv [\neg m(1) \wedge \neg m(2)] \vee i(1) \vee i(2)$$

$$g = i(1) \wedge i(2)$$

m(1)	0	0	1	1
m(2)	0	1	0	1
	m1	m2	m3	m4

i(1)	0	0	1	1
i(2)	0	1	0	1
	i1	i2	i3	i4

		R4				R3				R2				R1			
		m1	m2	m3	m4	m1	m2	m3	m4	m1	m2	m3	m4	m1	m2	m3	m4
m(1)	0	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
m(2)	0	0	1	1	0	0	1	1	0	0	1	1	0	0	1	1	0
i(1)	0	0	0	0	0	0	0	0	0	1	1	1	1	1	1	1	1
i(2)	0	0	0	0	1	1	1	1	0	0	0	0	0	1	1	1	1
	i1	i1	i1	i1	i2	i2	i2	i2	i3	i3	i3	i3	i3	i4	i4	i4	i4

Construcción del conjunto completo de complejos manifestación-interpretación

$$BLE = M \times I = \{m1i1, m1i2, m1i3, m1i4, m2i1, m2i2, m2i3, m2i4, m3i1, m3i2, m3i3, m3i4, m4i1, m4i2, m4i3, m4i4\}$$

← Aplicamos E para obtener BLR

$$BLR = \{m1i1, m3i2, m2i3, m3i3, m3i4, m4i4\}$$

El problema de la Incertidumbre: Razonamiento Bayesiano

El modelo categórico es poco realista porque el mundo real está lleno de observaciones ruidosas, sensores imperfectos, información incompleta y causas múltiples. Un síntoma (ej. fiebre) no implica de forma categórica una única enfermedad.

Para solventar esto, se usa la probabilidad entendida como un grado de creencia.

El Teorema de Bayes: Permite actualizar nuestras creencias a medida que obtenemos nueva evidencia. La fórmula clave calcula la probabilidad de una causa A dado que hemos observado un efecto o evidencia E:

$$P(A/E) = \frac{P(E/A)P(A)}{P(E)}$$

• Relaciona las probabilidades a priori (lo que creíamos antes) con las probabilidades a posteriori (lo que creemos tras observar la nueva evidencia). En el razonamiento médico/diagnóstico se formaliza usando conceptos vitales como los "verdaderos positivos", "falsos positivos", "falsos negativos" y usando las métricas de Sensibilidad y Especificidad de las pruebas.

	A	¬A	TOTAL
E	a	b	a + b
¬E	c	d	c + d
TOTAL	a + c	b + d	N

E = n° casos donde la prueba da positivo A = n° casos con X presente

a = positivos reales

b = falsos positivos

c = falsos negativos

d = negativos reales

$$\text{Bayes} \rightarrow P(A/E) = \frac{P(E/A)P(A)}{P(E)} : P(E) = \frac{(a+b)}{N}$$

$$a = (a+c)P(E/A) : b = (b+d)P(E/\neg A)$$

$$(a+c) = N \times P(A) : (b+d) = N \times P(\neg A)$$

$$a = N \times P(A) \times P(E/A) : b = N \times P(\neg A) \times P(E/\neg A)$$

$$P(E) = P(A)P(E/A) + P(\neg A)P(E/\neg A)$$

$$P(A/E) = \frac{P(E/A)P(A)}{P(E/A)P(A) + P(E/\neg A)P(\neg A)}$$

$$P(A/E) = \frac{P(E/A)P(A)}{P(E/A)P(A) + P(E/\neg A)P(\neg A)}$$

↳ Se puede generalizar a:

$$P(A_0/E) = \frac{P(E/A_0)P(A_0)}{\sum_i P(E/A_i)P(A_i)}$$

Limitaciones del Modelo Bayesiano Básico (Ingenuo): Aunque maneja la incertidumbre e integra evidencias, no escala bien computacionalmente si introducimos muchas variables. Requiere demasiados cálculos probabilísticos y asume independencias que a veces no son reales.



Redes bayesianas: La solución estructurada

Las Redes Bayesianas solucionan el problema de escalabilidad dotando de **estructura** matemática al problema.

Se representan visualmente mediante un Grafo Dirigido Acíclico.

- **Nodos:** Representan las variables aleatorias (síntomas, causas), y cada uno aloja una tabla de probabilidades condicionadas.
- **Aristas (Flechas):** Representan las dependencias probabilísticas directas entre los nodos.

La clave de su eficiencia (Independencia Condicional): La estructura visual del grafo codifica qué variables son condicionalmente independientes entre sí. Al no depender todas las variables de todas las demás, el número de probabilidades necesarias para calcular el sistema se reduce drásticamente.



Redes bayesianas vs Redes neuronales (Deep learning)

- **Redes Neuronales:** Aprenden y memorizan un único set de valores estáticos (pesos y sesgos) como un punto estimado ("caja negra").
- **Redes Bayesianas:** Representan esos pesos con distribuciones probabilísticas completas, capturando la incertidumbre intrínseca en sus predicciones.

¿Cuándo usar Redes Bayesianas? Son la herramienta predilecta frente al Machine Learning tradicional cuando:

1. Importa la explicabilidad (explicar por qué se tomó una decisión, vital en medicina o abogacía).
2. Se dispone de conocimiento experto valioso que se puede inyectar en el sistema.
3. Los datos son muy escasos o extremadamente ruidosos.
4. En modelos híbridos de IA que combinan IA simbólica con aprendizaje.