

Tema 9.- Otros modelos de sistemas conexionistas

A. Redes autoorganizativas (SOM- Self-Organizing Maps)

Introducción

Autoorganización en Biología: Proceso donde el comportamiento global del sistema surge solo de la interacción local entre sus componentes.

Autoorganización en Sistemas Conexionistas: Modificación repetida de los pesos en respuesta a modos de activación siguiendo unas reglas preestablecidas hasta que se desarrolla una estructura.


Aprendizaje No Supervisado: A diferencia del Backpropagation, aquí no hay una "salida deseada". La red descubre por sí sola regularidades, similitudes y clases en los datos de entrada.

Historia: Teuvo Kohonen (Universidad de Helsinki) es el creador del modelo más famoso, conocido como Mapas Autoorganizativos de Kohonen (SOM).

Fundamentos biológicos

El modelo se inspira en el funcionamiento de la corteza cerebral, donde las neuronas se organizan en láminas bidimensionales.

Mapas Somatotópicos: Estructuras cerebrales donde zonas vecinas de la corteza responden a estímulos de zonas vecinas del cuerpo (ej. la organización de los sentidos en el cerebro).



Arquitectura de la red de Kohonen




Características principales:

- Aprendizaje no supervisado y competitivo.
- Preservación de la topología: Entradas similares activan neuronas cercanas en la red.
- Transforma una entrada de muchas dimensiones en un mapa de 1 o 2 dimensiones.

Estructura:

- Capa de entrada: N neuronas (una por cada componente del vector de entrada).
- Capa de salida (Capa de Competición): Generalmente una rejilla 2D. Cada neurona de esta capa tiene un vector de pesos del mismo tamaño que la entrada.

Concepto de Vecindad: Cada neurona de salida tiene "vecinas" físicas. Cuando una neurona gana, ella y sus vecinas se mueven hacia el estímulo.





El algoritmo de aprendizaje

El proceso sigue tres etapas clave tras inicializar los pesos al azar:

1. Competición: Para cada patrón de entrada, se busca la neurona de la capa de salida cuyo vector de pesos sea el más parecido (normalmente usando la distancia euclidéa). Esta neurona es la Ganadora o BMU (Best Matching Unit).
2. Cooperación: La neurona ganadora determina quiénes son sus vecinas según una función de vecindad (normalmente una campana de Gauss).
3. Adaptación: Se actualizan los pesos de la ganadora y sus vecinas para que se parezcan más a la entrada actual.


- α (Factor de aprendizaje): Controla cuánto cambian los pesos. Disminuye con el tiempo.
- R (Radio de vecindad): Define hasta dónde llega la influencia de la ganadora. También disminuye con el tiempo (empieza grande y acaba centrado solo en la ganadora).



Representación geométrica

Una demostración visual fundamental del funcionamiento de los SOM son sus mapas topológicos bidimensionales.

- Coordenadas: Las coordenadas de los prototipos (puntos en el mapa) equivalen a los pesos de las células de la capa competitiva.
- Evolución: A medida que entran patrones, la red los aprende y varía el valor de sus conexiones, trasladando los pesos hacia donde están las entradas. Donde hay mayor densidad de entradas, habrá más densidad de neuronas.
- Calidad de la red: Se puede comprobar de forma visual si la red se está comportando correctamente observando si las líneas de conexión no se cruzan.
- Prototipos sin datos: Puede darse el caso (ej. distribución toroidal) de que haya puntos (prototipos) que no queden asociados a ningún vector de entrada, los cuales se pasarán por alto en la fase de operación.




Aplicaciones: tipos de problemas que resuelve el SOM

Dependiendo del problema, la salida de un SOM se interpretará de una forma u otra. Se dividen en 4 categorías principales:

1. Agrupamiento de patrones (Clustering): Permite separar los datos en grupos sin saber a priori cuántos existen. Sirve para caracterizar cada grupo usando los pesos de la neurona ganadora.
2. Prototipado: Similar al clustering, pero el interés se centra en obtener el prototipo del grupo (ej. para compresión de imágenes).
3. Análisis de Componentes Principales: Sirve para detectar qué atributos caracterizan más a los datos, permitiendo reducir la dimensionalidad eliminando entradas redundantes sin pérdida significativa de información.
4. Extracción y relación de características: Busca organizar los datos de forma que entradas similares generen respuestas en zonas próximas del mapa. Estas categorías no son excluyentes (se puede reducir la dimensionalidad y luego hacer clustering).

Ejemplos prácticos de aplicación

- El Problema del Viajante (TSP): Se soluciona colocando las células en un vecindario unidimensional (una circunferencia). Los vectores de pesos son atraídos hacia las coordenadas 2D de las ciudades, ajustándose hasta crear el camino más corto. La solución recae en el vecindario y el orden topológico, no en la posición aislada.
- Delimitar un vaso sanguíneo: Usando un proceso análogo al del viajante, las neuronas en circunferencia son atraídas a los 322 puntos del contorno difuso del vaso en una mamografía.
- Mapa de la Pobreza Mundial: Organiza a los países en un mapa 2D a partir de un vector de 39 indicadores sociodemográficos. Países con riqueza similar activan neuronas próximas.
- WebSOM: Agrupa documentos de texto de Internet estructurándolos por temática (documentos similares acaban en zonas próximas), permitiendo la navegación en niveles de zoom.




Ventajas e inconvenientes

Ventajas: Son transparentes a los datos de entrada, adaptan localmente los vectores a la probabilidad de los datos, son muy fáciles de visualizar por su topología en malla y se integran fácilmente con otras técnicas.

Limitaciones e Inconvenientes:

- Arquitectura estática: Hay que determinar exactamente el tamaño y forma de la red antes de entrenar y no se puede cambiar durante el proceso.
- Neuronas muertas: Algunas neuronas pueden quedar muy lejos de las entradas y nunca llegar a ganar ni a ser entrenadas.
- Efecto bordes: Las neuronas exteriores del mapa no representan fielmente la distribución de la probabilidad.
- Efecto contracción: Las neuronas de los bordes sufren un efecto "imán" hacia los puntos centrales.
- Neuronas interpolantes: Pueden quedar neuronas situadas en zonas del espacio donde la densidad de probabilidad de los datos es completamente nula (vacío).
- Su inicialización es crítica y son caras computacionalmente al subir la dimensión de los datos.



B. Otros modelos autoorganizados - Crecimiento de redes

Crecimiento de redes

El problema de los SOM: Obligan a definir la topología de la red a priori (lo cual es difícil si no se conocen bien los datos) y su estructura es estática. La solución: Redes que empiezan con muy pocas neuronas (elementos de proceso) y determinan su estructura de forma autónoma adaptándose a los datos.

Mecanismos clave:

- Inserción: Basada en el valor resource (error de cuantización). Cada cierto tiempo, se insertan neuronas en las zonas con mayor error.
- Borrado: Se eliminan neuronas cuya probabilidad de ser activadas sea muy baja, ya que no compensa el "coste" de mantenerlas.

Modelo Growing Cell Structures - GCS




Propuesto por B. Fritzke (1994), es un modelo no supervisado para clustering.

Característica principal: Mantiene siempre una estructura k-dimensional básica y estricta en la capa de salida (k=1 segmento, k=2 triángulo, k=3 tetraedro).

Aprendizaje (Diferencias con SOM):

- Utiliza dos tasas de aprendizaje constantes: una para la neurona ganadora y otra para sus vecinas inmediatas.
- NO utiliza función de vecindad decreciente en el tiempo.

Aplicación típica: Diagnóstico de tumores analizando microarrays de ADN de alta dimensión.



Modelo Growing Neural Gas - GNG


Propuesto por Fritzke (1995).

- Diferencia fundamental con el GCS: NO mantiene ninguna estructura k-dimension estricta.

- Características: Trabaja insertando y borrando aristas libremente. Una unidad puede tener muchos más de 4 vecinos, formando figuras geométricas muy diversas. Tiene mayor capacidad de aprendizaje.

Aplicaciones clave:

- Soluciona 'The two Spiral Benchmark' (separar dos espirales entrelazadas).
- Lectura Óptica de Caracteres (OCR): Segmenta dibujos y letras sin necesidad de aprender las formas de antemano.



Conclusiones del crecimiento de redes

1. Tienen una topología autoadaptativa e independiente del usuario.
2. Requieren pocos parámetros y son constantes (en Kohonen variaban con el tiempo).
3. Mejores estimaciones de probabilidad: evitan las "neuronas interpolantes" al no posicionar neuronas en zonas sin datos.
4. Aunque son no supervisadas, pueden adaptarse a tareas de clasificación supervisada.